

DISCIPLINA	Aprendizado de Máquina	CÓDIGO:	IBM0787
CARGA HORÁRIA	80h	PERÍODO:	6º
PROFESSOR:	Daniel Trevisan Bravo – danie.bravo@professores.ibmec.edu.br	MATRÍCULA:	47610599

1. Ementa

Estudo dos principais conceitos, técnicas e algoritmos de aprendizado de máquina supervisionado e não supervisionado. Preparação de dados para modelagem, construção e validação de modelos preditivos. Aplicações práticas com uso de bibliotecas Python. Avaliação de modelos por métricas de desempenho e testes estatísticos. Introdução a métodos híbridos e ensemble.

2. Contextualização

Essa disciplina faz integração com as disciplinas da trilha de Programação dos currículos dos cursos de tecnologia.

3. Perfil docente

Profissionais graduados em Engenharia de Computação, Ciência da Computação ou áreas afins com pós-graduação strictu sensu, reconhecido pela Capes (mestre ou doutor).

4. Objetivos

1. Compreender os fundamentos teóricos do aprendizado de máquina supervisionado e não supervisionado.
2. Aplicar técnicas de preparação de dados e engenharia de atributos para uso em modelos preditivos.
3. Construir, treinar e avaliar modelos utilizando algoritmos clássicos com bibliotecas em Python.
4. Interpretar os resultados dos modelos e selecionar os melhores métodos com base em métricas apropriadas.
5. Explorar modelos híbridos e ensembles, promovendo o desenvolvimento de soluções mais robustas.

5. Conteúdos

1. Apresentação do curso: As etapas do processo do aprendizado de máquina: preparação dos dados, modelagem, avaliações dos modelos, previsões.
2. Introdução ao Aprendizado de Máquina: Definições e conceitos básicos; Diferença entre aprendizado supervisionado e não-supervisionado.
3. Revisão dos pré-requisitos da base de dados para a aprendizagem de máquina: tratamento de dados (outliers, missing etc.) e engenharia de atributos (criação de features, extração, seleção).
4. Modelos de regressão linear simples e múltipla: definições, conceito de correlação, correlação e causalidade, variáveis dependentes e independentes, erros; métricas de análise de desempenho.
5. Estudo de Adequação do Modelo: Análise de resíduos; Testes de suposições e diagnóstico de modelos.
6. Regressão Polinomial: Introdução e aplicações; Ajuste de curvas complexas.
7. Regressão Logística: Modelagem de variáveis binárias; Análise e interpretação dos coeficientes. Técnicas de balanceamento de classes: subamostragem e superamostragem de dados.
8. Modelo dos k-vizinhos próximos: definição; conceito teórico; aplicações. Bibliotecas e módulos para aplicação do modelo. Treino e teste de modelo dos k-vizinhos. Escolhendo número ótimo de vizinhos. Validação do modelo: métricas e resultados desejáveis.
9. Conceitos teóricos Árvores de decisão: árvores, nó, raiz, altura da árvore. Índices de impureza: definições e aplicações. Treino e teste do modelo. Definição de altura ótima. Validação do modelo: métricas e resultados desejáveis.
10. Modelo de árvores de decisão: regressão e classificação. Modelagem e aplicações específicas de cada tipo de árvore.
11. Random Forest: Introdução ao método de ensemble; Vantagens e aplicações práticas.
12. Support Vector Machine (SVM): Conceitos básicos e kernel trick; Aplicações em problemas lineares e não-lineares.
13. Seleção e Validação de Modelos:
Técnicas de validação cruzada; Critérios para seleção de Métricas de avaliação de modelos: acurácia, precisão, revocação, F1-score, curva ROC e matriz de confusão.
14. Modelos Híbridos: combinação de métodos supervisionados e não supervisionados que operam de forma conjunta.

6. Metodologia / Procedimentos de ensino

O processo ensino aprendizagem é orientado para a aprendizagem significativa, optando-se por metodologias problematizadoras, práticas, investigativas e participativas. Considerando-se o perfil da disciplina, o processo ensino aprendizagem será desenvolvido mediante aulas expositivas dialogadas, estudo de casos, debates e seminários sobre temas previamente definidos, respeitando a liberdade de cátedra do Professor e em conformidade com a premissa institucional de adoção de metodologias ativas, diversificadas e, verdadeiramente hábeis ao desenvolvimento das competências necessárias ao perfil do egresso pretendido.

Tempo para estudo semanal extraclasse exigido pela disciplina: No mínimo 3h por semana para revisão de conteúdo e resolução semanal de exercícios.

Conhecimento de disciplinas de semestres anteriores importantes: Programação Estruturada, Programação para Análise de Dados e Extração e Preparação de Dados.

Uso da Inteligência Artificial nas atividades propostas na disciplina: A inteligência artificial deve ser incorporada às atividades escolares não como uma ferramenta de substituição do pensamento crítico, mas como um catalisador do aprendizado. É fundamental enfatizar que o aluno não deve apenas copiar e colar as respostas geradas automaticamente; em vez disso, os recursos da IA generativa devem ser utilizados como um suporte consultivo para comparar resultados, validar hipóteses e aprofundar a compreensão dos conteúdos. Além disso, a tecnologia se mostra uma excelente aliada na hora de otimizar a visualização de informações, permitindo que os estudantes refinem a criação de gráficos e diagramas, tornando-os mais claros, precisos e eficientes para a interpretação e análise de dados.

Controle de Frequência e Abono de Faltas: A presença em aula será aferida por meio de chamada oral, realizada em qualquer instante da aula, sendo que ao aluno que não estiver presente ou não responder à chamada, será atribuída falta na respectiva aula. Quando, por alguma razão, o professor não vier a realizar a chamada, todos os alunos receberão presença na respectiva aula. O abono de faltas será realizado apenas mediante solicitação formal pelo sistema da faculdade (pelos motivos previstos no estatuto da instituição), sendo que quaisquer outras solicitações serão automaticamente indeferidas.

Vistas e feedbacks das avaliações: As vistas (feedback) das avaliações serão realizadas somente de forma presencial, nas datas e horários das aulas descritos na planilha de planos de aulas.

Encerramento do Semestre: O período letivo se estende até o final da semana de Avaliação Substitutiva (AS). Portanto, é imprescindível que os alunos não agendem compromissos pessoais ou viagens antes do término dessa semana.

7. Procedimentos de Avaliação

Os procedimentos de avaliação contemplarão competências e habilidades desenvolvidas durante a disciplina e seguirão orientações da Norma 06: Critérios para Cálculo das Notas da Avaliação do Desempenho Acadêmico (IBMEC):

As avaliações realizadas para aferir a aprendizagem do aluno nas disciplinas dos cursos de graduação devem ser expressas por meio das seguintes notas:

$$\text{Média Final} = (0,4 \times \text{AP1}) + (0,4 \times \text{AP2}) + (0,2 \times \text{AC})$$

Respeitado o limite mínimo de frequência de 75%, previsto no Regimento Interno da Instituição, será considerado aprovado o aluno que obtiver Média Final igual ou superior a 7 (sete).

8. Procedimentos de Avaliação

Avaliações	Descrição do sistema de avaliação:	Observação / Critérios:
AP1	Prova individual prática, realizada no aplicativo Pycharm	Temas abordados na avaliação: todo o conteúdo dado até a semana anterior ao da AP1
AP2	Prova individual prática, realizada no aplicativo Pycharm	Temas abordados na avaliação: todo o conteúdo dado até a semana anterior ao da AP2.
AC	Desenvolvimento de exercícios práticos em laboratório, contemplando o conteúdo.	Será considerada a média aritmética de todas as ACs aplicadas no decorrer do semestre. As notas das ACs poderão ser revisadas pelos alunos até o dia 12/11/2026.
AS	Prova individual prática, realizada no aplicativo Pycharm	Temas abordados na avaliação: todo o conteúdo desenvolvido no semestre. Esta avaliação facultativa substituirá a menor nota tirada nas avaliações AP1 ou AP2.

9. Bibliografia Básica				
	AUTOR	TÍTULO	Volume, Local, Editora	ANO
B1	FACELI, K; LORENA, A. C; GAMA, J; ALMEIDA, T. A.; CARVALHO, A. C. P. L. F.	Inteligência Artificial: Uma abordagem de aprendizado de máquina	Rio de Janeiro: Grupo GEN	2021
B2	GÉRON, A.	Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow: Conceitos, Ferramentas e Técnicas para a Construção de Sistemas Inteligentes	Rio de Janeiro: Editora Alta Books	2021
B3	HARRISON, M.	Machine Learning – Guia de Referência Rápida: Trabalhando com dados estruturados em Python	São Paulo: Editora Novatec	2019

10. Bibliografia Complementar				
	AUTOR	TÍTULO	Volume, Local, Editora	ANO
C1	ESCOVEDO, T.; KOSHIYAMA, A.	Introdução a Data Science: Algoritmos de Machine Learning e métodos de análise	São Paulo: Casa do Código	2020
C2	GRUS, J.	Data Science do Zero: noções fundamentais com Python	Rio de Janeiro: Editora Alta Books	2021
C3	PIERSON, L.	Data Science para Leigos	Rio de Janeiro: Editora Alta Books	2019
C4	SICSÚ, A. L.; SAMARTINI, A.; BARTH, N. L.	Técnicas de machine learning	São Paulo: Editora Blucher	2023
C5	MCKINNEY, W.	Python para Análise de Dados	Rio de Janeiro: Novatec Editora	2023

AULAS	PLANO DE AULAS	Disciplina: IBM0787 – Aprendizado de Máquina
Dia/Mês	Conteúdo da Aula	Atividades de Apoio
04/08	Apresentação da disciplina e do professor. As etapas do processo do aprendizado de máquina: preparação dos dados, modelagem, avaliações dos modelos e previsões.	C1, Capítulo 1.
06/08	Introdução ao Aprendizado de Máquina: Definições e conceitos básicos; Diferença entre aprendizado supervisionado e não-supervisionado.	B1, Capítulo 1 (Introdução); B2, Parte 1 (Capítulo 1).
11/08	Revisão dos pré-requisitos da base de dados para a aprendizagem de máquina: tratamento de dados (outliers, missing etc.) e engenharia de atributos (criação de features, extração, seleção).	B1, Capítulo 1 (Parte 1); B2, Parte 1 (Capítulo 2); B3, Capítulo 3, 4, 5 e 7; C1, Capítulo 4; C2, Capítulo 3; C4, Capítulo 2.
13/08	Aula de exercícios: estudos de caso envolvendo tratamento de dados e engenharia de atributos.	
18/08	Modelo de regressão linear simples: definições, conceito de correlação, correlação e causalidade, variáveis dependentes e independentes, erros; métricas de análise de desempenho.	B2, Parte 1 (Capítulo 4); B3, Capítulo 14; C1, Capítulo 7 e 8; C4, Capítulo 4.
20/08	Modelo de regressão linear múltipla: definições, conceito de correlação, correlação e causalidade, variáveis dependentes e independentes, erros; métricas de análise de desempenho.	B2, Parte 1 (Capítulo 4); B3, Capítulo 14; C1, Capítulo 7 e 8; C4, Capítulo 4.
25/08	Aula de exercícios: estudos de caso envolvendo treinamento, predições e avaliação de desempenho dos modelos de regressão simples e múltipla.	
27/08	Estudo de Adequação dos Modelos de Regressão: Análise de resíduos; Testes de suposições e diagnóstico de modelos.	B3, Capítulo 15; C4, Capítulo 3.
01/09	Modelo de Regressão Polinomial: Introdução e aplicações; Ajuste de curvas complexas.	C1, Capítulo 7 e 8.
03/09	Aula de exercícios: estudos de caso envolvendo treinamento, predições e avaliação de desempenho dos modelos de regressão polinomial.	
08/09	Regressão Logística: Modelagem de variáveis binárias; Análise e interpretação dos coeficientes. Técnicas de balanceamento de classes: subamostragem e superamostragem de dados. Aula de exercícios: estudos de caso envolvendo treinamento, predições e avaliação de desempenho dos modelos de regressão logística.	B2, Parte 1 (Capítulo 4); B3, Capítulo 10; C1, Capítulo 5 e 6; C4, Capítulo 5.

AULAS	PLANO DE AULAS	Disciplina: IBM0787 – Aprendizado de Máquina
Dia/Mês	Conteúdo da Aula	Atividades de Apoio
10/09	TESTE DE PROGRESSO	
15/09	Modelo dos k-vizinhos próximos: definição; conceito teórico; aplicações. Bibliotecas e módulos para aplicação do modelo. Treino e teste de modelo dos kvizinhos. Escolhendo número ótimo de vizinhos. Validação do modelo: métricas e resultados desejáveis.	B3, Capítulo 10 e 14; C1, Capítulo 5 e 6; C4, Capítulo 10.
17/09	Modelo dos k-vizinhos próximos: escolhendo número ótimo de vizinhos. Validação do modelo: métricas e resultados desejáveis. Aula de exercícios: estudos de caso envolvendo treinamento, previsões e avaliação de desempenho dos modelos dos k-vizinhos próximos.	B3, Capítulo 10 e 14; C1, Capítulo 5 e 6; C4, Capítulo 10.
22/09	Revisão para a AP1.	Exercícios práticos durante a aula, envolvendo todo conteúdo ministrado até o momento.
24/09	SEMANA DE PROVAS – AP1	
29/09	SEMANA DE PROVAS – AP1	
01/10	Entrega e revisão da AP1.	Correção da prova, esclarecimento de dúvidas e possíveis correções das notas.
06/10	Conceitos teóricos Árvores de decisão: árvores, nó, raiz, altura da árvore. Índices de impureza: definições e aplicações. Treino e teste do modelo. Definição de altura ótima. Validação do modelo: métricas e resultados desejáveis.	B2, Parte 1 (Capítulo 6); B3, Capítulo 10 e 14; C4, Capítulo 6.
08/10	Modelo de árvores de decisão: regressão e classificação. Modelagem e aplicações específicas de cada tipo de árvore.	B2, Parte 1 (Capítulo 6); B3, Capítulo 10 e 14; C4, Capítulo 6.
13/10	FERIADO	
15/10	Aula de exercícios: estudos de caso envolvendo treinamento, previsões e avaliação de desempenho dos modelos de regressão e classificação de árvores de decisão.	
20/10	Random Forest: Introdução ao método de ensemble; Vantagens e aplicações práticas.	B2, Parte 1 (Capítulo 7); B3, Capítulo 10 e 14; C4, Capítulo 7.
22/10	Aula de exercícios: estudos de caso envolvendo treinamento, previsões e avaliação de desempenho dos modelos Random Forest.	
27/10	Support Vector Machine (SVM): Conceitos básicos e kernel trick; Aplicações em problemas lineares e não-lineares.	B2, Parte 1 (Capítulo 5);

AULAS	PLANO DE AULAS	Disciplina: IBM0787 – Aprendizado de Máquina
Dia/Mês	Conteúdo da Aula	Atividades de Apoio
		B3, Capítulo 10 e 14; C4, Capítulo 10.
29/10	Estudos de caso que exploram, em profundidade, a comparação entre distintos modelos de classificação, destacando suas vantagens, limitações e comportamentos em diferentes cenários.	B2, Parte 1 (Capítulos 4, 5, 6 e 7); B3, Capítulo 10 e 14; C1, Capítulo 5 e 6; C4, Capítulos 5, 6, 7 e 10.
03/11	Seleção e Validação de Modelos: Técnicas de validação cruzada; Critérios para seleção de Métricas de avaliação de modelos. Exercícios: estudos de caso envolvendo técnicas de seleção e validação de modelos.	B2, Parte 1 (Capítulo 3); B3, Capítulo 10; C4, Capítulo 7.
05/11	Modelos Híbridos: combinação de métodos supervisionados e não supervisionados que operam de forma conjunta. Exercícios: estudos de caso envolvendo modelos híbridos.	B2, Parte 1 (Capítulo 3); B3, Capítulo 10; C4, Capítulo 7.
10/11	Revisão para a AP2.	Exercícios práticos durante a aula, envolvendo todo conteúdo ministrado até o momento.
12/11	SEMANA DE PROVAS – AP2	
17/11	SEMANA DE PROVAS – AP2	
19/11	Entrega e revisão da AP2.	Correção da prova, esclarecimento de dúvidas e possíveis correções das notas.
24/11	Revisão para a AS.	Exercícios práticos durante a aula, envolvendo todo conteúdo ministrado até o momento.
26/11	SEMANA DE PROVAS – AS	
01/12	SEMANA DE PROVAS – AS	
03/12	Entrega e revisão da AS.	Correção da prova, esclarecimento de dúvidas e possíveis correções das notas.