

Regressão Linear Simples

Prof. Dr. Daniel Trevisan Bravo

Introdução

- A **regressão linear** é uma técnica de análise de dados que prevê o valor de dados (contínuos) desconhecidos usando outro valor de dados relacionado e conhecido. Ele modela matematicamente a variável desconhecida ou dependente e a variável conhecida ou independente como uma equação linear.
- Gera uma equação que descreve a relação estatística entre uma ou mais variáveis preditoras (X) e a variável resposta (y). A regressão linear encontra a linha que melhor representa as variáveis de entrada com a variável de saída.
- Exemplos:


X (atributos preditores)	y (variável resposta – alvo)
Metragem do imóvel, número de cômodos, localização	Valor do imóvel
Temperatura, umidade e pressão do ar	Velocidade do vento
Gastos no cartão de crédito, histórico	Limite do cartão
Distância (km)	Consumo do veículo

Tipos de regressão linear

- **Simples**: utilizada para modelar a relação entre duas variáveis. Exemplos: Idade influencia na altura em crianças.
- **Múltipla**: o conjunto de dados contém uma variável dependente e várias variáveis independentes. Exemplo: Metragem do imóvel, número de cômodos e localização influenciam no valor do imóvel.
- **Logística**: mede a probabilidade de um evento ocorrer. A previsão é um valor entre 0 e 1, em que 0 indica um evento improvável de acontecer e 1 indica a probabilidade máxima de que esse evento aconteça. Equações logísticas usam funções logarítmicas para calcular a linha de regressão. Exemplo: a probabilidade de uma imagem ser uma fruta ou um animal.


Quando aplicar a regressão linear?

- Deve existir uma relação linear entre as variáveis independentes (X) e dependentes (y). Para determinar essa relação, os cientistas de dados criam um gráfico de dispersão (uma coleção aleatória de valores X e y) para ver se eles se encaixam em uma linha reta.
- Se isso não acontecer, será possível aplicar funções não lineares, como raiz quadrada ou logarítmica, para criar matematicamente a relação linear entre as duas variáveis.



Como funciona a regressão linear simples?

- Uma técnica de **regressão linear simples** tenta traçar um gráfico de linhas entre duas variáveis de dados, X e y




Exemplo de regressão linear simples

- Exemplo: A tabela a seguir relaciona as distâncias percorridas por carros (km) e seu consumo de combustível (litros), em uma amostra de 10 carros novos.

Distância (X)	Consumo (y)
20	1.33
60	5.45
15	1.66
45	3.46
35	2.92
80	6.15
70	4.11
73	5.00
28	2.95
85	6.54

Exemplo de regressão linear simples



β_0 (intercepto): representa o ponto onde a reta corta o eixo y (na maioria das vezes não possui interpretação prática).

β_1 (coeficiente angular): representa a variabilidade em y causada pelo aumento de uma unidade em x.

Coeficientes do modelo de regressão

- β_1 (coeficiente angular):

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{\sum_{i=1}^n x_i^2 - n \bar{x}^2}.$$

- β_0 (intercepto):

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

OBS: $\bar{x}$ é a média dos valores da
variável independente
 $\bar{y}$ é a média dos valores da
variável dependente

Coeficientes do modelo de regressão - Exemplo

- Coeficientes da regressão:

$$\sum_{i=1}^n x_i y_i = 2419.60, \quad \sum_{i=1}^n x_i^2 = 32113$$

$$\bar{x} = 51.10 \quad \text{e} \quad \bar{y} = 3.957$$

$$\hat{\beta}_1 = \frac{2419.60 - 10 \cdot 51.10 \cdot 3.957}{32113 - 10 \cdot (51.10)^2} = \frac{397.573}{6000.9} = 0.0663$$

$$\hat{\beta}_0 = 3.957 - 0.0663 \cdot 51.10 = 0.5716$$

Equação do modelo de regressão - Exemplo

$$y = \hat{\beta}_0 + \hat{\beta}_1 x$$



$$y = 0.5716 + 0.0663.X$$

- Calculando y a partir de um novo valor de x:



$$y = 0.5716 + 0.0663.100 = 7,21$$

Distância (X)	Consumo (y)
20	1.33
60	5.45
15	1.66
45	3.46
35	2.92
80	6.15
70	4.11
73	5.00
28	2.95
85	6.54
100	7,21

Avaliação do modelo de regressão – Métricas mais usadas

- **R-Quadrado**, ou Coeficiente de Determinação, é uma métrica que visa expressar a quantidade da variância dos dados que é explicada pelo modelo construído. Essa medida, que varia de 0 a 1, calcula qual a porcentagem da variância que pôde ser prevista pelo modelo de regressão e, portanto, nos diz o quão “próximo” as medidas reais estão do nosso modelo.

$$R^2 = 1 - \frac{\text{Variança Residual}}{\text{Variança Total}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$



Avaliação do modelo de regressão – Métricas mais usadas

- **Erro médio quadrado (MSE):** métrica mais utilizada, consiste na média do erro das previsões ao quadrado. Em outras palavras, pega-se a diferença entre o valor predito pelo modelo e o valor real, eleva-se o resultado ao quadrado, faz-se a mesma coisa com todos os outros pontos, soma-os, e divide-se pelo número de elementos preditos. Quanto **maior** esse número, **pior** o modelo.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$$

Avaliação do modelo de regressão – Métricas mais usadas

- Para o exemplo das distâncias percorridas por carros (km) e seu consumo de combustível (litros), temos:

R-Quadrado = 0.8980 (em geral, quanto mais próximo de 1, melhor o modelo)

MSE = 0.2995 (em geral, quanto mais próximo de 0, melhor o modelo)



www.ibmec.br

 /ibmec

 ibmec

 @ibmec_oficial

 ibmec

