

Regularização em Regressões


Prof. Dr. Daniel Trevisan Bravo

Introdução

- Um dos desafios comuns no desenvolvimento de modelos de regressão é o overfitting.
- O overfitting ocorre quando um modelo se torna muito complexo e começa a capturar não apenas a tendência subjacente nos dados, mas também o ruído.
- Isso significa que ele tem um bom desempenho com os dados de treinamento, mas um desempenho ruim com dados novos e desconhecidos.
- O overfitting é problemático porque reduz a generalização e o poder preditivo do modelo em dados do mundo real, que é o objetivo principal da maioria dos modelos de regressão.
- Possíveis soluções: aumentar a quantidade de dados, usar modelos mais simples e com menos features, aplicar técnicas de regularização ou usar a validação cruzada para melhor uso dos dados.

Introdução - Overfitting vs Underfitting

- Overfitting: aprende o ruído dos dados em vez da tendência subjacente real. Como resultado, suas previsões são menos precisas quando expostas a dados do mundo real.
- Underfitting: Modelo muito simples, não captura padrões reais.



Causas do overfitting

- Muitas “features”: ter muitas variáveis preditoras, especialmente as irrelevantes, pode levar o modelo a ajustar o ruído nos dados.
- Amostras insuficientes: um pequeno conjunto de dados pode levar o modelo a aprender com ruído e valores discrepantes em vez dos verdadeiros padrões subjacentes.
- Complexidade do modelo: modelos altamente complexos (como regressão polinomial de alto grau) são propensos a overfitting, pois podem se adaptar muito aos dados de treinamento.
- Falta de regularização: não usar técnicas, como regularização, pode levar a modelos muito complexos.

Consequências do overfitting

- Generalização ruim: a principal consequência é que o modelo tem bom desempenho em dados de treinamento, mas ruim em dados não vistos.
- Avaliação enganosa de modelos: modelos superajustados podem mostrar excelentes métricas de desempenho em dados de treinamento, mas falhar em cenários do mundo real.
- Previsões não confiáveis: previsões feitas por modelos superajustados não são confiáveis e geralmente são incorretas quando aplicadas a novos dados.

Introdução - O que é Regularização?

- Técnica usada em análise de regressão para evitar overfitting e melhorar a generalização de modelos. Ela envolve modificar o processo de aprendizado para penalizar a complexidade do modelo.
- Adiciona uma penalização à função de perda, visando assim limitar a complexidade.
- Ao controlar a complexidade do modelo, a regularização ajuda a alcançar um equilíbrio entre a capacidade do modelo de ajustar os dados de treinamento e sua capacidade de generalizar para novos dados.

Regularização: Como funciona?

- A regularização adiciona um termo de penalização à função de custo.
- Essa penalidade “desencoraja” o modelo a se ajustar muito próximo aos dados de treinamento.
- Nova função de custo:

$$J(\theta) = \text{Erro} + \lambda \cdot \text{Penalização}$$

- λ controla a força da regularização.

Tipos de regularização

- Regularização L1 (**Lasso**):
 - Penaliza a soma dos valores absolutos dos coeficientes.
 - Tende a zerar coeficientes menos relevantes (esparsidade), incentivando a escassez nos coeficientes do modelo.
 - Deve ser definido o λ para a penalidade.
 - Ao aumentar λ , você aumenta a penalidade, o que pode levar alguns coeficientes a zero, removendo efetivamente essas features do modelo.
 - Usada para seleção de variáveis.

Tipos de regularização

- Regularização L2 (**Ridge**):
 - Penaliza a soma dos quadrados dos coeficientes.
 - Deve ser definido o λ para a penalidade.
 - Reduz os coeficientes, mas geralmente não zera.
 - Mantém todas as variáveis, reduzindo a influência das menos importantes.
- Combinação de L1 e L2 – **Elastic Net**
 - Flexível e eficaz quando há muitas variáveis correlacionadas.
 - Deve ser definido o λ para a penalidade e o l1_ratio, que se for igual a 1, a participação da regressão Lasso é de 100% e Ridge 0% e vice-versa.

Exemplo: Regressão Lasso (Regularização L1)

- Exemplo: Imagine um conjunto de dados em que você prevê preços de imóveis com base em características como tamanho, número de quartos, idade da casa, proximidade do centro da cidade e assim por diante.
- Na **regressão Lasso**, se o modelo determinar que a "proximidade do centro da cidade" tem impacto mínimo nos preços dos imóveis, seu coeficiente pode ser reduzido a zero, removendo-o efetivamente da equação de previsão. Isso leva a um modelo mais simples, focado nas características mais relevantes.

Exemplo: Regressão Ridge (Regularização L2)

- Exemplo: Usando o mesmo conjunto de dados de previsão de preços de imóveis, a regressão de **Ridge** não eliminará nenhuma característica como Lasso.
- Em vez disso, reduzirá os coeficientes de características menos importantes, como "proximidade do centro da cidade". Isso garante que todas as características contribuam para o modelo, mas seu impacto seja ponderado de acordo com sua significância. Isso é benéfico em cenários em que cada característica tem algum nível de influência no resultado.

Critérios de decisão para escolha do método de regularização apropriado

- Lasso: Quando você suspeita que apenas um subconjunto de features é importante.
- Ridge: Quando você espera que a maioria das features contribua para o resultado.

Conclusão

- Tanto em Lasso quanto em Ridge, a escolha de λ é crucial. Normalmente, é determinada por meio de validação cruzada. Um λ maior impõe uma penalidade maior aos coeficientes, resultando em modelos mais simples, mas defini-lo muito alto pode simplificar demais o modelo, causando underfitting.



www.ibmec.br

 /ibmec

 ibmec

 @ibmec_oficial

 ibmec

